

Introduzione

- **Problema:** Se siamo in grado di prevedere con accuratezza se il primo stadio del razzo atterrerà con successo dopo il lancio, possiamo stimare con precisione il costo reale della missione. Questa informazione è di fondamentale valore strategico per un'azienda concorrente che intenda formulare un'offerta commerciale competitiva contro SpaceX per l'assegnazione di contratti spaziali. L'obiettivo di questo progetto è quindi costruire un'intera pipeline di Data Science per predire questo esito.

Metodologia:

- **Raccolta Dati:** Abbiamo integrato due fonti principali: chiamate REST alle API ufficiali di SpaceX via Python ed estrazione tramite web scraping dalle tabelle HTML di Wikipedia utilizzando BeautifulSoup.
- **Data Wrangling:** Abbiamo gestito i valori mancanti (come l'imputazione della media per la massa del carico útil PayloadMass) e ingegnerizzato la variabile target Class (1 per atterraggio riuscito, 0 altrimenti), applicando il One-Hot Encoding per le variabili categoriche.
- **Exploratory Data Analysis (EDA):** Abbiamo interrogato il database tramite query SQL (con SQLite) per estrarre aggregazioni sui carichi e sui booster (es. i 45.596 kg totali trasportati per la NASA), affiancandovi un'analisi spaziale con mappe interattive Folium e una dashboard integrata in Plotly Dash.
- **Modellazione:** Abbiamo addestrato e confrontato 4 algoritmi di Machine Learning: Logistic Regression, Support Vector Machine, Decision Tree e K-Nearest Neighbors

Estrazione dati da API SPACE X

1. Chiamata GET all'API di SpaceX (https://api.spacexdata.com/v4/launches/past).
2. Conversione del JSON ottenuto in un DataFrame Pandas (pd.json_normalize).
3. Estrazione dei dettagli di ciascun lancio interrogando i vari endpoint collegati.
4. Filtraggio dei soli dati riguardanti il razzo **Falcon 9**

<https://github.com/frbag01/testIBM/blob/main/jupyter-labs-spacex-data-collection-api.ipynb>

	FlightNumber	Date	BoosterVersion	PayloadMass	Orbit	LaunchSite	Outcome	Flights	GridFins	Reused
4	1	2010-06-04	Falcon 9	6123.547647	LEO	CCSFS SLC 40	None None	1	False	False
5	2	2012-05-22	Falcon 9	525.000000	LEO	CCSFS SLC 40	None None	1	False	False
6	3	2013-03-01	Falcon 9	677.000000	ISS	CCSFS SLC 40	None None	1	False	False
7	4	2013-09-29	Falcon 9	500.000000	PO	VAFB SLC 4E	False Ocean	1	False	False
8	5	2013-12-03	Falcon 9	3170.000000	GTO	CCSFS SLC 40	None None	1	False	False

Raccolta Dati

1. Richiesta HTTP alla pagina Wikipedia dei lanci del Falcon 9 tramite `requests.get()`.
 2. Parsing dell'HTML tramite la libreria **BeautifulSoup** (`soup = BeautifulSoup(html_content, 'html.parser')`).
 3. Individuazione e iterazione sulle tabelle HTML (`<table class="wikitable">`).
 4. Estrazione di colonne chiave: *Flight Number*, *Date*, *Booster Version*, *Launch Site*, *Payload*, *Outcome*.
- <https://github.com/frbag01/testIBM/blob/main/jupyter-labs-webscraping.ipynb>

Data Wrangling


- Gestione dei valori mancanti (es. PayloadMass riempito con la media).
- Creazione della variabile target **Class**:
 - 1 = Atterraggio riuscito del primo stadio (*True Ocean, True ASDS, True RTLS*).
 - 0 = Atterraggio fallito o non tentato (*False Ocean, False ASDS, None, etc.*).
- **Trasformazione (One-Hot Encoding)**:
- Conversione delle variabili categoriche (*LaunchSite, Orbit, LandingPad*) in variabili dummy usando `pd.get_dummies()`.

<https://github.com/frbag01/testIBM/blob/main/labs-jupyter-spacex-Data%20wrangling.ipynb>

Data Visualization


I siti di lancio KSC LC-39A e VAFB SLC-4E mostrano una percentuale di successo significativamente più alta rispetto a CCAFS SLC-40,

<https://github.com/frbag01/testIBM/blob/main/edadataviz.ipynb>



Analisi Esplorativa dei Dati con SQL

- **Nomi dei siti di lancio unici:**
- *Query:* `SELECT DISTINCT Launch_Site FROM SPACEXTBL;`
- *Risultato:* Trovati i 4 siti principali (CCAFS LC-40, VAFB SLC-4E, KSC LC-39A, CCAFS SLC-40).
- **Massa totale del carico (Payload) trasportato dalla NASA:**
- *Query:* `%sql select sum(PAYLOAD_MASS__KG_) from SPACEXTBL WHERE Customer = 'NASA (CRS)';`
- *Risultato:* 45596.
- **Tasso di successo degli atterraggi per intervallo di date e massa:**
- *Query:* `%sql select Booster_Version FROM SPACEXTBL WHERE Landing_Outcome = 'Success (drone ship)' AND PAYLOAD_MASS__KG_ > 4000 AND PAYLOAD_MASS__KG_ < 6000;`
- *Risultato:*
 - F9 FT B1022
 - F9 FT B1026
 - F9 FT B1021.2
 - F9 FT B1031.2
- https://github.com/frbag01/testIBM/blob/main/jupyter-labs-eda-sql-coursera_sqlite.ipynb




- Tutti i siti di lancio si trovano in prossimità della costa (per motivi di sicurezza durante le traiettorie di lancio) e vicino all'equatore (per sfruttare la velocità di rotazione terrestre).

- **Funzionalità della Dashboard:**

- **Dropdown Menu:** Permette di selezionare un singolo sito di lancio (es. *CCAFS LC-40*, *KSC LC-39A*) oppure *"All Sites"* per una panoramica globale.
- **Pie Chart (Grafico a Torta):** Mostra la percentuale di lanci riusciti vs. falliti per il sito selezionato (o la quota totale dei successi divisi per sito).
- **Scatter Plot (Grafico a Dispersione):** Mette in relazione la massa del carico utile con il successo dell'atterraggio, con codifica colore in base alla versione del booster (*Booster Version Category*).


- **Risultati Chiave (Key Insights):**

- **Sito con la percentuale di successo più alta:** KSC LC-39A (~76.9%).
- **Massa del carico ottimale:** I lanci con Payload compreso tra 2.000 kg e 5.000 kg mostrano il tasso di successo più elevato.
- **Performance delle versioni Booster:** La versione **FT (Full Thrust)** e la **B5 (Block 5)** mostrano tassi di successo nettamente superiori rispetto alle prime versioni v1.0 e v1.1.
- https://github.com/frbag01/testIBM/blob/main/lab_jupyter_launch_site_location.ipynb



Analisi dei Modelli e Valutazione delle Performance

- **Logistic Regression, Support Vector Machine (SVM), Decision Tree Classifier, e K-Nearest Neighbors (KNN).** Tutti gli algoritmi hanno mostrato prestazioni molto simili ed elevate sul validation set (accuratezza media attorno all'83%-87%), a dimostrazione della validità del preprocessing e dell'efficacia delle feature estratte.
- Il modello ha una **richiamo (Recall) del 100%** per la classe degli atterraggi riusciti, mentre la principale sorgente di errore risiede nei **Falsi Positivi** (sovrastima lieve delle capacità di atterraggio nei casi limite).
- Durante la fase di addestramento e cross-validation, l'albero di decisione (DecisionTreeClassifier) ha registrato il **punteggio di accuratezza più alto (87.5%)** tra tutti i modelli testati, L'albero di decisione riesce a catturare le relazioni non lineari tra le caratteristiche di lancio (es. combinazione di massa del carico utile *PayloadMass*, sito di lancio e orbita target) in modo altamente interpretabile.



Risultati Chiave:

- **Siti e Carichi:** Il sito KSC LC-39A registra il tasso di successo più alto (~76.9%), e la fascia di carico ideale per l'atterraggio è compresa tra 2.000 kg e 5.000 kg.
- **Evoluzione Tecnologica:** Le versioni recenti del booster, in particolare la *FT* e la *Block 5 (B5)*, garantiscono prestazioni nettamente superiori rispetto ai primi prototipi.
- **Miglior Modello:** Tutti i modelli hanno registrato un'ottima accuratezza base (83%-87.5%), ma l'albero di decisione (DecisionTreeClassifier) si è distinto come il migliore con un'accuratezza del **87.5%** in cross-validation.